Laboratorio 6.
Modelos de Regresión Logística

INTRODUCCIÓN:

La empresa **SmartStay Advisors** es una firma intermediaria que facilita la búsqueda y selección de propiedades en Airbnb para clientes corporativos y particulares.

El modelo operativo es el siguiente:

- El cliente proporciona requerimientos específicos (ciudad, presupuesto, tipo de propiedad, capacidad, duración de estancia).
- SmartStay analiza la oferta disponible y propone propiedades que optimicen precio, calidad y disponibilidad.
- Airbnb ofrece incentivos económicos a SmartStay cuando logra incrementar el nivel de ocupación de propiedades con bajo desempeño.

La empresa desea implementar modelos de minería de datos que le permitan:

1. Estimar precios competitivos.
2. Identificar propiedades con baja ocupación.
3. Comprender qué factores influyen en la ocupación y los ingresos.
4. Diseñar estrategias basadas en datos para aumentar la rentabilidad.

Conjunto de datos a utilizar

- listings.RData

Resultados esperados en la Quinta Entrega:

Se espera la entrega de un informe detallado donde incluya:

- Los modelos de Regresión Logística para clasificación usando la variable dicotómica y la variable categórica de los precios que creó.
- Una comparación para estimar la categoría de los precios de las viviendas donde determine qué algoritmo funcionó mejor (Árboles de regresión, Random Forest, Bayes Ingenuo, KNN, Regresión Logística). Compare los resultados del mejor modelo de cada uno de los algoritmos. Recuerde que para establecer una comparación válida, es necesario comparar bajo las mismas condiciones. Mismo conjunto de datos de entrenamiento y de prueba.
- Un informe con las explicaciones de los pasos que llevó a cabo y los resultados obtenidos en la generación y aplicación de los modelos. Recuerde que la investigación debe ser reproducible por lo que debe guardar el código que ha utilizado.
- Como la vez anterior, le han pedido un informe formal, que enlace los temas usando subtítulos explicativos que mantenga al lector en un hilo conductual de los temas que aborda la consultoría. No incluya los enunciados de las actividades de esta guía como subtítulos.

Notas:

- La consultoría es en grupo, por lo que solo se tendrán en cuenta los grupos conformados por más de un especialista.
- Cada individuo será evaluado de forma individual basado en sus aportes al trabajo grupal, por lo que deben versionar el código para poder revisar las contribuciones de cada uno.

ACTIVIDADES

1. Cree una variable dicotómica por cada una de las categorías de la variable respuesta categórica que creó en hojas anteriores. Debería tener 3 variables dicotómicas (valores 0 y 1) una que diga si el airbnb es caro o no, medio o no, económico o no.
2. Use los mismos conjuntos de entrenamiento y prueba que utilizó en las hojas anteriores.
3. Elabore un modelo de regresión logística para conocer si una vivienda es cara o no, utilizando el conjunto de entrenamiento y explique los resultados a los que llega. El experimento debe ser reproducible por lo que debe fijar que los conjuntos de entrenamiento y prueba sean los mismos siempre que se ejecute el código. Use validación cruzada. Ponga el umbral de decisión en 0.5.
4. Analice el modelo. Determine si hay multicolinealidad en las variables, y cuáles son las que aportan al modelo, por su valor de significación. Haga un análisis de correlación de las variables del modelo y especifique si el modelo se adapta bien a los datos.
5. Utilice el modelo con el conjunto de prueba y determine la eficiencia del algoritmo para clasificar.
6. Explique si hay sobreajuste (overfitting) o no (recuerde usar para esto los errores del conjunto de prueba y de entrenamiento). Muestre las curvas de aprendizaje usando los errores de los conjuntos de entrenamiento y prueba.
7. Haga un tuneo del modelo para determinar los mejores parámetros, recuerde que los modelos de regresión logística se pueden regularizar como los de regresión lineal. Use
8. Haga un análisis de la eficiencia del algoritmo usando una matriz de confusión. Tenga en cuenta la efectividad, donde el algoritmo se equivocó más, donde se equivocó menos y la importancia que tienen los errores, el tiempo y la memoria consumida. Para esto último puede usar “profvis” si trabaja con R y “cProfile” en Python.
9. ¿El umbral de decisión en 0.5 es lo mejor para este conjunto de datos? Pruebe con otros umbrales de decisión. Apóyese en el índice de Youden para determinar el umbral que le de más balance entre la especificidad y la sensibilidad. Use la sensibilidad, especificidad y la importancia de los errores para justificar su decisión. Cree una nueva matriz de confusión y compárela con la del modelo con umbral de decisión en 0.5.
10. Determine cual de todos los modelos es mejor, puede usar AIC y BIC para esto, además de los parámetros de la matriz de confusión y los del profiler.
11. Haga un modelo de regresión logística para la variable categórica para el precio de las casas (categorías: barata, media y cara). Asegúrese de tunearlo para obtener el mejor modelo posible.
12. Compare la eficiencia del modelo anterior con los de clasificación de las entregas anteriores ¿Cuál se demoró más en procesar?¿Cuál se equivocó más?¿Cuál se equivocó menos?¿por qué?

EVALUACIÓN

Notas: Tiene que poderse comprobar su aporte al trabajo grupal a través de commits. Si no existen al menos 3 commits con su aporte significativo no va a tener nota de la hoja de trabajo. Utilice una herramienta que permita registrar los aportes de cada uno.

- **(20 puntos)** Análisis de los modelos generados. Explique todos los razonamientos. Uso de las métricas correctas
- **(10 puntos).** Tuneo de parámetros. Se probó con varios valores para los hiperparámetros. Se explican los resultados.
- **(10 puntos).** Tuneo del umbral de decisión, mediante el índice de Youden, especificidad, sensibilidad e importancia de los errores, comparación con umbral de decisión por defecto.
- **(15 puntos)** Análisis de los modelos generados para la variable dicotómica. Explicación de resultados.
- **(20 puntos)** Matriz de confusión de cada modelo de clasificación. Explicación de los resultados obtenidos. Selección del mejor modelo usando las métricas adecuadas. Análisis de otras métricas además del accuracy para los modelos generados.
- **(15 puntos)** Comparación del modelo de clasificación de Regresión Logística con el mejor modelo de clasificación de todas las entregas pasadas (KNN, Árbol de Decisión, Random Forest, Naive Bayes). Elección del mejor modelo de clasificación basado en las métricas adecuadas.
- **(10 puntos)** El informe de resultados está bien redactado, se establece una continuidad lógica en las explicaciones y el análisis de los modelos. Tiene un hilo conductor claro que no pierde al lector y no tiene las actividades de esta guía como subtítulos.

MATERIAL A ENTREGAR

- Archivo .rmd, .ipynb o Google docs con el informe con lo solicitado en las instrucciones
- Script de R o de Python que utilizó debidamente organizado y comentado (Si utilizó .rmd debe añadir el .html que se genera)
- Link del repositorio utilizado para la hoja de trabajo.

FECHAS DE ENTREGA

- **PASAPORTE:** Puntos del 1 al 6 de la sección de actividades: viernes 17 de abril
- **ENTREGA FINAL:** domingo, 19 de abril a las 23:59

NOTAS:

- No se aceptará ningún resultado sin explicaciones de los hallazgos y/o análisis.
- Para poder tener nota completa debe entregar las asignaciones en el tiempo adecuado. No se calificará el avance (pasaporte) de la entrega si no fue subido en tiempo, aunque esté en el repositorio.
- Si alguno de los miembros del grupo de trabajo no llega al trabajo colaborativo en clase, no tendrá derecho a la nota del laboratorio.
- La descripción y explicación de resultados es crucial en el análisis de los datos por lo que no se tomarán en cuenta gráficos o tablas que no estén explicadas ni para avances ni para entrega final.
- Se tomarán en cuenta las contribuciones individuales para calificar el trabajo de cada uno, si no tiene suficientes contribuciones significativas en código y en análisis no tiene derecho a nota.